# Multiplicative Weights Update for Maximizing Network Connectivity

ゼミ資料

# 今日の構成

**問題：限られた重みを辺に配分して，グラフの連結性を最大化する．**

1. **勾配法の基礎** — 勾配降下法と射影
2. **Mirror descentとMWU** — 距離の一般化，指数更新，リグレット保証
3. **ゲームとしての統一的解釈** — 弱点への攻撃，最適応答と優勾配
4. **有向グラフ** — ANF / global mincut の最大化
5. **無向グラフ** — algebraic connectivity の最大化

# 共通の問題設定：辺の重み配分

$n = |V| \geq 2$，$m = |E| \geq 2$．配分変数の総和を 1 に正規化する．

$$\Delta_E = \left\{ w \in \mathbb{R}^E_{\geq 0} : \sum_{e \in E} w_e = 1 \right\}, \qquad \mathrm{OPT} = \max_{w \in \Delta_E} \mathrm{OBJ}(w).$$

| 指標 $\mathrm{OBJ}(w)$ | グラフ | 指標の意味 |
|---|---|---|
| global mincut | 有向 | 最も容量の小さい有向カット |
| ANF | 有向 | 全順序付き頂点対の最大流の平均 |
| $\lambda_2(L(w))$ | 無向 | グラフラプラシアンの第二固有値 |

いずれも $w$ に関する**凹関数**．

# 1．勾配法の基礎

# 1-1．勾配降下法

微分可能な凸関数 $f : \mathbb{R}^d \to \mathbb{R}$ の最小化を考える．

$$\nabla f(x) = \left( \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right)^\top, \qquad \langle a, b \rangle = \sum_{i=1}^{d} a_i b_i.$$

$\nabla f$ は各座標方向の偏微分を並べた **勾配**，$\langle a, b \rangle$ は **内積**． 点 $x_t$ における $f$ の一次近似は，以下のように書ける：

$$f(x) \approx f(x_t) + \langle \nabla f(x_t), x - x_t \rangle.$$

勾配と逆向きに進むと，一次近似の値が減少する．

$$\boxed{x_{t+1} = x_t - \eta \nabla f(x_t)}, \qquad \eta > 0 : \text{ステップ幅}.$$

参照：伊藤 勝（2019）「凸最適化問題に対する一次法とその理論」§2–3，pp.326–327.

# 1-2．射影勾配法

凸制約 $x \in K$ があるとき，先の更新結果を制約条件内に射影する必要がある．

$$y_{t+1} = x_t - \eta \nabla f(x_t), \qquad x_{t+1} = \Pi_K(y_{t+1}).$$

ここで $\Pi_K(y) = \arg\min_{x \in K} \|x - y\|_2^2$ は閉凸集合 $K$ への射影． 平方完成により，同じ更新を次の最小化として表せる：

$$x_{t+1} = \arg\min_{x \in K} \left\{ f(x_t) + \langle \nabla f(x_t), x - x_t \rangle + \frac{1}{2\eta} \|x - x_t\|_2^2 \right\}.$$

参照：伊藤（2019），§3，式(3).

# 2．Mirror descentとMWU

# 2-1．最大化では「優勾配」を使う

**定義（優勾配）**．凹関数 $\mathrm{OBJ}$ に対し，$g_t$ が次を満たすとき優勾配といい，$g_t \in \partial^+ \mathrm{OBJ}(w_t)$ と書く：

$$\mathrm{OBJ}(u) \leq \mathrm{OBJ}(w_t) + \langle g_t, u - w_t \rangle \qquad (\forall u \in \Delta_E).$$

- 微分可能なら $g_t = \nabla \mathrm{OBJ}(w_t)$．
- 微分できなくても，関数を上から支える一次式を使える．
- $-g_t$ は凸関数 $-\mathrm{OBJ}$ の劣勾配である．

## 2-1．Mirror descentとMWU

微分可能な凸関数 $\psi$ から **Bregman divergence** $D_\psi$ を定める：

$$D_\psi(x, y) = \psi(x) - \psi(y) - \langle \nabla\psi(y), x - y \rangle.$$

優勾配 $g_t$，$R > 0$ に対し，凹最大化のmirror descentは

$$w_{t+1} = \arg\max_{w \in \Delta_E} \left\{ \frac{\eta}{R} \langle g_t, w \rangle - D_\psi(w, w_t) \right\}.$$

単体上で負エントロピーを選ぶと

$$\psi(w) = \sum_e w_e \log w_e, \qquad D_\psi(w, w_t) = \sum_e w_e \log \frac{w_e}{w_{t,e}}.$$

Lagrange乗数を $\nu$ とすると，最適性条件 $\eta g_{t,e}/R - \log(w_{t+1,e}/w_{t,e}) - 1 - \nu = 0$ より

$$w_{t+1,e} = \frac{w_{t,e} \exp(\eta g_{t,e}/R)}{\sum_f w_{t,f} \exp(\eta g_{t,f}/R)} \qquad (\mathrm{MWU}) \ .$$

参照：Beck–Teboulle 2003

# 2-2．MWUの実行手順

優勾配の各成分が $0 \leq g_{t,e} \leq R$ とする．

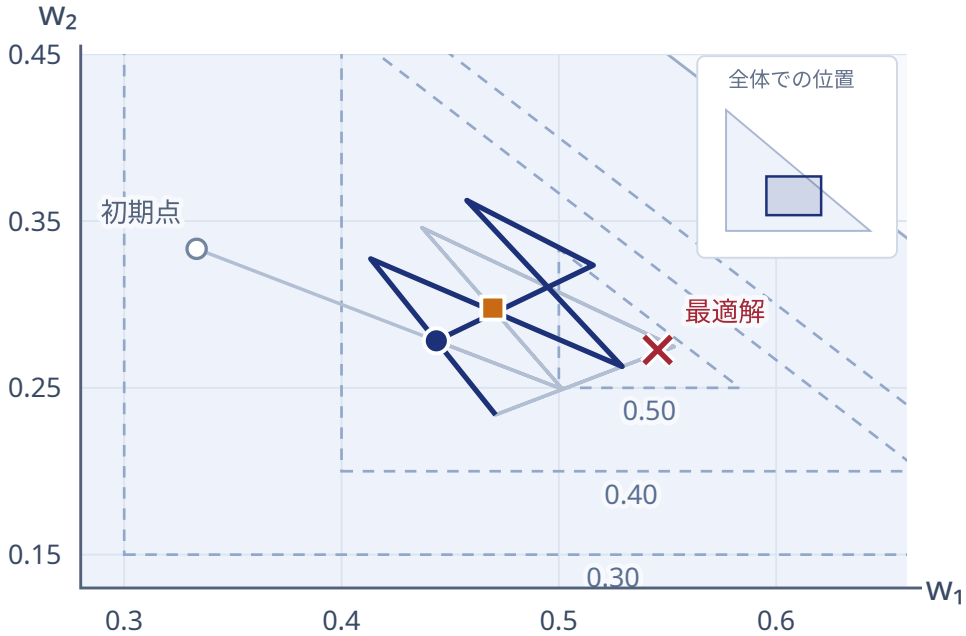
1. **初期化**：$w_{1,e} = 1/m$．
2. **勾配の計算**：現在の $w_t$ に対する優勾配 $g_t$ を求める．
3. **乗法更新**：$w_{t+1,e} \propto w_{t,e} \exp(\eta g_{t,e}/R)$．
4. **平均を出力**：$\bar{w}_T = \frac{1}{T}\sum_{t=1}^{T} w_t$．

> 大きな優勾配を持つ辺の**相対的な重み**が増える．
> 保証するのは平均配分の目的値であり，毎回の単調増加ではない．

# 2-2．二次元平面で見るMWUの動き

$\mathrm{OBJ}(w) = \min\{w_1, 2w_2, 3w_3\}$ を $w \in \Delta_3$ 上で最大化する．$R = 3$.

軌跡付近を拡大　　全体を表示




$w_3 = 1 - w_1 - w_2$ ／ 破線：目的値の等高線

## 反復 **25** / 120

● **現在**　■ **平均**　× **最適解**

w = (0.444, 0.278, 0.278)

| | |
|---|---|
| 現在の目的値 | **0.444** |
| 平均配分の目的値 | **0.470** |
| 最適値 6/11 | **0.545** |

濃い線：直近6回の更新
薄い線：それ以前の軌跡

再生　1回進む　リセット

反復

ステップ幅 η　0.7　変更時にリセット

次は w1 に exp(η × 1/3) を掛けて正規化．

# 2-3．リグレットの定義

**定義2.1**．各時刻 $t$ に配分 $w_t \in \Delta_E$ を選び，その後に利得ベクトル $g_t \in [0, R]^E$ を受け取る．
ある配分 $u \in \Delta_E$ に対し

$$\mathrm{Reg}_T(u) := \sum_{t=1}^{T} \langle g_t, u \rangle - \sum_{t=1}^{T} \langle g_t, w_t \rangle .$$

最も良い配分との比較を

$$\mathrm{Reg}_T := \max_{u \in \Delta_E} \mathrm{Reg}_T(u) = \max_{e \in E} \sum_{t=1}^{T} g_{t,e} - \sum_{t=1}^{T} \langle g_t, w_t \rangle$$

と定める．比較対象 $u$ は全時刻で同じ配分を使う．

$\mathrm{Reg}_T / T$ が小さければ，事後に選ぶ最良の固定配分に対して，1回あたりの利得の差が小さい．

# 2-3．MWUのリグレット保証

**補題2.2**．$m \geq 2$，$R > 0$，$T \geq 1$ とする．任意の利得列 $g_t \in [0, R]^E$ に対し，$w_{1,e} = 1/m$ から

$$w_{t+1,e} = \frac{w_{t,e} e^{\eta g_{t,e}/R}}{\sum_f w_{t,f} e^{\eta g_{t,f}/R}} \qquad (\eta > 0)$$

で更新すると

$$\mathrm{Reg}_T \leq \frac{R \log m}{\eta} + \frac{\eta R T}{2}.$$

特に $\eta = \sqrt{2 \log m / T}$ とすれば

$$\frac{\mathrm{Reg}_T}{T} \leq R \sqrt{\frac{2 \log m}{T}}.$$

# 2-3．補題2.2の証明：KLの差

$\ell_t = g_t/R$，$Z_t = \sum_e w_{t,e} e^{\eta \ell_{t,e}}$ とおく．更新式は $w_{t+1,e} = w_{t,e} e^{\eta \ell_{t,e}} / Z_t$ なので

$$\log \frac{w_{t+1,e}}{w_{t,e}} = \eta \ell_{t,e} - \log Z_t.$$

ある配分 $u \in \Delta_E$ に対し，$D_t := D_{\mathrm{KL}}(u \| w_t) = \sum_e u_e \log(u_e / w_{t,e})$ とすると

$$\begin{aligned} D_t - D_{t+1} &= \sum_e u_e \left( \log \frac{u_e}{w_{t,e}} - \log \frac{u_e}{w_{t+1,e}} \right) \\ &= \sum_e u_e \log \frac{w_{t+1,e}}{w_{t,e}} \\ &= \eta \sum_e u_e \ell_{t,e} - \log Z_t \sum_e u_e = \eta \langle u, \ell_t \rangle - \log Z_t. \end{aligned}$$

$\sum_e u_e = 1$ と $g_t = R \ell_t$ を用いて整理すると

$$\langle g_t, u - w_t \rangle = \frac{R}{\eta} \left[ D_t - D_{t+1} + \log Z_t - \eta \langle w_t, \ell_t \rangle \right].$$

# 2-3．Hoeffdingの補題

**補題**．$0 \le X \le 1$ を満たす確率変数と $s \ge 0$ に対し

$$\log \mathbb{E}[e^{sX}] \le s\mathbb{E}[X] + \frac{s^2}{8}.$$

指数を取って平均した量を，元の平均と二次項で抑える不等式である．

**MWUへの適用**．$\Pr(I_t = e) = w_{t,e}$ として辺の添字 $I_t$ を選び，$X_t = \ell_{t,I_t} \in [0,1]$ とおくと

$$\mathbb{E}[X_t] = \sum_e w_{t,e}\ell_{t,e} = \langle w_t, \ell_t \rangle, \qquad \mathbb{E}[e^{\eta X_t}] = \sum_e w_{t,e} e^{\eta \ell_{t,e}} = Z_t.$$

従って $s = \eta$ を代入すれば

$$\log Z_t - \eta \langle w_t, \ell_t \rangle \le \frac{\eta^2}{8} \le \frac{\eta^2}{2}.$$

参照：W. Hoeffding, “Probability Inequalities for Sums of Bounded Random Variables,” JASA 58, 13–30 (1963).

# 2-3．Hoeffdingの補題の証明

$H(s) = \log \mathbb{E}[e^{sX}]$ とおく．指数で重みを付け直した期待値を

$$\mathbb{E}_s[\varphi(X)] := \frac{\mathbb{E}[\varphi(X)e^{sX}]}{\mathbb{E}[e^{sX}]}$$

と書けば，微分により

$$H'(s) = \frac{\mathbb{E}[Xe^{sX}]}{\mathbb{E}[e^{sX}]} = \mathbb{E}_s[X],$$

$$H''(s) = \frac{\mathbb{E}[X^2e^{sX}]}{\mathbb{E}[e^{sX}]} - \left(\frac{\mathbb{E}[Xe^{sX}]}{\mathbb{E}[e^{sX}]}\right)^2 = \mathbb{E}_s[X^2] - (\mathbb{E}_s[X])^2.$$

$0 \le X \le 1$ から $X^2 \le X$．$\mu_s = \mathbb{E}_s[X] \in [0,1]$ とおくと

$$H''(s) \le \mu_s - \mu_s^2 = \frac{1}{4} - \left(\mu_s - \frac{1}{2}\right)^2 \le \frac{1}{4}.$$

$H(0) = 0$，$H'(0) = \mathbb{E}[X]$ より，2回積分して

$$H(s) - s\mathbb{E}[X] = \int_0^s (s-r)H''(r)\,dr \le \frac{1}{4}\int_0^s (s-r)\,dr = \frac{s^2}{8}. \quad \square$$

# 2-3．補題2.2の証明：反復について和を取る

KLの差の式とHoeffdingの評価を合わせると

$$\langle g_t, u - w_t \rangle \le \frac{R}{\eta}(D_t - D_{t+1}) + \frac{\eta R}{2}.$$

$t = 1, \dots, T$ について足すと，中間のKLが打ち消し合う：

$$\begin{aligned}
\mathrm{Reg}_T(u) &= \sum_{t=1}^{T} \langle g_t, u - w_t \rangle \\
&\le \frac{R}{\eta}\left[(D_1 - D_2) + (D_2 - D_3) + \cdots + (D_T - D_{T+1})\right] + \frac{\eta R T}{2} \\
&= \frac{R}{\eta}(D_1 - D_{T+1}) + \frac{\eta R T}{2}.
\end{aligned}$$

初期値 $w_{1,e} = 1/m$ と $u_e \le 1$ から

$$D_1 = \sum_e u_e \log(m u_e) = \log m + \sum_e u_e \log u_e \le \log m.$$

$D_{T+1} \ge 0$ を用い，$u$ について最大化すれば

$$\mathrm{Reg}_T = \max_{u \in \Delta_E} \mathrm{Reg}_T(u) \le \frac{R \log m}{\eta} + \frac{\eta R T}{2}. \quad \square$$

# 2-3．補題2.2の証明：ステップ幅の選択

$T$ で割った上界を $B(\eta)$ とおく：

$$\frac{\mathrm{Reg}_T}{T} \le B(\eta) := \frac{R\log m}{\eta T} + \frac{\eta R}{2}.$$

第1項は $\eta$ が大きいほど小さく，第2項は大きくなる．微分して

$$B'(\eta) = -\frac{R\log m}{\eta^2 T} + \frac{R}{2} = 0 \quad \Longrightarrow \quad \eta = \sqrt{\frac{2\log m}{T}}.$$

この値では二つの項が等しくなり

$$\frac{R\log m}{\eta T} = \frac{R}{2}\sqrt{\frac{2\log m}{T}}, \qquad \frac{\eta R}{2} = \frac{R}{2}\sqrt{\frac{2\log m}{T}}.$$

従って $\mathrm{Reg}_T/T \le R\sqrt{2\log m/T}$ を得る．□

# 2-3．リグレットから最適化誤差へ

**定理2.3**．連続な凹関数 $\mathrm{OBJ} : \Delta_E \to \mathbb{R}$ に対し，各 $w_t$ で優勾配 $g_t \in [0, R]^E$ が得られるとする．

補題2.2のMWUを $\eta = \sqrt{2 \log m / T}$ で実行し，平均配分

$$\bar{w}_T = \frac{1}{T} \sum_{t=1}^{T} w_t$$

を出力すると

$$\mathrm{OPT} - \mathrm{OBJ}(\bar{w}_T) \leq R \sqrt{\frac{2 \log m}{T}}.$$

**証明の流れ**：凹性で平均配分を評価し，優勾配不等式でリグレットに帰着する． 詳細は次頁．

# 2-3．定理2.3の証明

最適配分を $w^\star$ とする．凹性（Jensenの不等式）より

$$\mathrm{OBJ}\left(\frac{1}{T}\sum_t w_t\right) \geq \frac{1}{T}\sum_t \mathrm{OBJ}(w_t).$$

両辺を $\mathrm{OPT} = \mathrm{OBJ}(w^\star)$ から引くと

$$\begin{aligned}\mathrm{OPT} - \mathrm{OBJ}(\bar{w}_T) &\leq \mathrm{OPT} - \frac{1}{T}\sum_t \mathrm{OBJ}(w_t) \\ &= \frac{1}{T}\sum_t \big[\mathrm{OBJ}(w^\star) - \mathrm{OBJ}(w_t)\big].\end{aligned}$$

優勾配の定義に $u = w^\star$ を代入すれば

$$\mathrm{OBJ}(w^\star) - \mathrm{OBJ}(w_t) \leq \langle g_t, w^\star - w_t \rangle.$$

従って，リグレットの定義と補題2.2を使って

$$\mathrm{OPT} - \mathrm{OBJ}(\bar{w}_T) \leq \frac{\mathrm{Reg}_T(w^\star)}{T} \leq \frac{\mathrm{Reg}_T}{T} \leq R\sqrt{\frac{2\log m}{T}}. \quad \square$$

# 3．ネットワーク最適化のゲーム解釈

# 3-1．ネットワーク最適化をゲームとして見る

配分側は辺への重み配分 $p$ を選び，攻撃側はその配分に対する弱点 $a$ を選ぶ．

$$\max_{p \in \Delta_E} \min_{a \in \mathcal{A}} h(p, a), \qquad h(p, a) = \langle g(a), p \rangle.$$

**配分側（Max）**

限られた予算を辺に配る．
最も弱い部分の評価を高めたい．

**攻撃側（Min）**

指標に応じた弱点を選ぶ．
現在の配分の評価を低くしたい．

指標値は，現在の配分に対する攻撃側の最適応答の値：
$\mathrm{OBJ}(p) = \min_{a \in \mathcal{A}} h(p, a)$．

# 3-2．配分側はMWUで攻撃に応答する

$0 \le g_{t,e} \le R$ とし，現在の配分からの変化をKLで抑えながら利得を高める：

$$p_{t+1} = \arg\max_{p \in \Delta_E} \left\{ \frac{\eta}{R} \langle g_t, p \rangle - \mathrm{KL}(p \| p_t) \right\}.$$

$$p_{t+1,e} = \frac{p_{t,e} \exp(\eta g_{t,e}/R)}{\sum_f p_{t,f} \exp(\eta g_{t,f}/R)}.$$

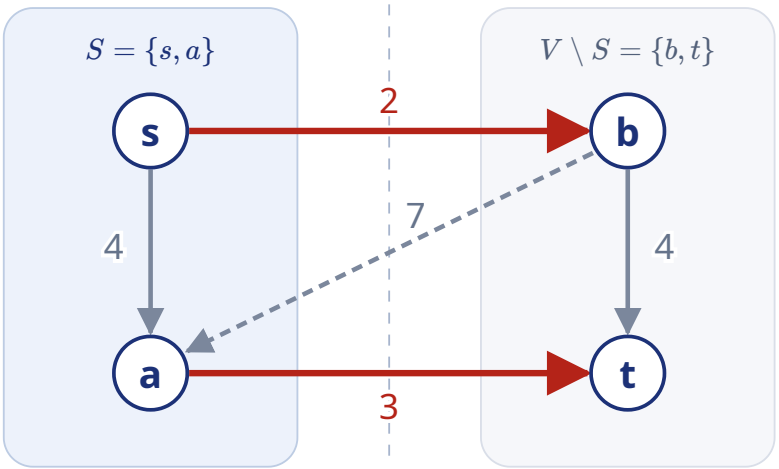
**配分を提示** → **弱点への攻撃** → **勾配の計算** → **配分の更新** を繰り返す．

これまでの攻撃に対する後悔を小さくすることで，平均配分 $\bar{p}_T$ の値が ゲームの最適値 $\max_p \min_a h(p,a)$ に近づく．

# 4．ANF / global mincut 最大化

# 4-1．有向 $s$–$t$ mincut の定義

有向グラフ $G=(V,E)$，辺の容量 $x_e \geq 0$ を考える．$s \in S$，$t \notin S$ とする．




$$\delta^+(S)=\{(u,v)\in E : u\in S,\ v\notin S\},$$

$$c_x(S)=\sum_{e\in\delta^+(S)} x_e.$$

- 数えるのは $S$ **から出る辺**．
- 図の $b \to a$ は逆向きなので数えない．
- $S$ の内部の辺も数えない．

$$c_x(S)=2+3=5.$$

$$\kappa_{st}(x)=\min_{\substack{S\subseteq V\\ s\in S,\ t\notin S}} c_x(S)=s\text{から}t\text{への最大流量}.$$

# 4-1．Global mincut と ANF

**Global mincut**：$\emptyset \neq S \subsetneq V$ となるカットのうち，容量が最小のもの．
$S$ と $V \setminus S$ の両方に頂点がある，という条件を課す．

$$\kappa_{\mathrm{glob}}(x) = \min_{\emptyset \neq S \subsetneq V} c_x(S) = \min_{s \neq t} \kappa_{st}(x).$$

**ANF（Average Network Flow）**：全順序付き頂点対の最大流の平均

$$\mathrm{ANF}(x) = \frac{1}{n(n-1)} \sum_{s \neq t} \kappa_{st}(x).$$

各ペアを独立に評価する．ANFの平均は $(s,t)$ と $(t,s)$ を別々に数える．

# 4-1．予算を辺の容量に配分する

各辺の既存容量は $0$ とする．総予算 $1$ を配分し，$p_e$ を辺 $e$ の容量とする．

$$x(p) = p, \qquad p \geq 0, \quad \sum_e p_e \leq 1.$$

$$\mathrm{OBJ}(p) = \kappa_{\mathrm{glob}}(p) \quad \text{または} \quad \mathrm{ANF}(p), \qquad \mathrm{OPT} = \max_{p \in \Delta_E} \mathrm{OBJ}(p).$$

- どちらの指標も，容量を増やして値が下がることはない．
- 残りの予算を任意の辺に配れるので，$\sum_e p_e = 1$ としてよい．
- $\mathrm{OBJ}$ は $p$ に関する凹関数．MWUで配分を更新する．

# 4-2．Global mincut のゲーム

配分側は $p \in \Delta_E$，攻撃側は $\emptyset \neq S \subsetneq V$ を選ぶ．カットを固定した利得は

$$h_{\mathrm{cut}}(p, S) = \sum_{e \in \delta^+(S)} p_e.$$

したがって，容量配分問題は

$$\max_{p \in \Delta_E} \min_{\emptyset \neq S \subsetneq V} h_{\mathrm{cut}}(p, S).$$

- **攻撃側の最適応答**：現在の容量 $p$ に対する最小カット．
- **配分側の応答**：そのカットに含まれる辺の重みを相対的に増やす．

# 4-2．Global mincut の勾配の計算

**補題4.1**．$a_S \in \{0,1\}^E$ を，$\delta^+(S)$ の指示ベクトルとする．

$$\mathrm{OBJ}(p) = \min_S \langle a_S, p \rangle.$$

現在の容量 $p_t$ の最小カット $S_t$ を一つ選ぶと，$g_t = a_{S_t}$ は $p_t$ における優勾配である．

**証明**．任意の $u \in \Delta_E$ に対して

$$\mathrm{OBJ}(u) \le \langle a_{S_t}, u \rangle = \mathrm{OBJ}(p_t) + \langle a_{S_t}, u - p_t \rangle.$$

$g_{t,e} = \mathbf{1}\{e \in \delta^+(S_t)\}$　が優勾配．

# 4-2．ANFのゲーム

$\mathcal{S}_{sr} = \{S \subseteq V : s \in S,\ r \notin S\}$ とする． 攻撃側は，各頂点対のカットをまとめた族 $\mathcal{S} = (S_{sr})_{s \neq r}$ を選ぶ．

$$h_{\mathrm{ANF}}(p, \mathcal{S}) = \frac{1}{n(n-1)} \sum_{s \neq r} \sum_{e \in \delta^+(S_{sr})} p_e .$$

$$\max_{p \in \Delta_E} \min_{\mathcal{S} \in \prod_{s \neq r} \mathcal{S}_{sr}} h_{\mathrm{ANF}}(p, \mathcal{S}).$$

各ペアのカットは独立に選べるため，最小値は各ペアの最大流の平均と一致する．

頂点対は一様に平均する．攻撃側の最適応答は，各ペアについて最小カットを選ぶこと．

# 4-2．ANFの勾配の計算

**補題4.2**．各順序付きペア $(s,r)$ の，現在の最小カットを $S_{sr}^{(t)}$ とする．

$$g_{t,e} = \frac{1}{n(n-1)} \sum_{s \neq r} \mathbf{1}\{e \in \delta^{+}(S_{sr}^{(t)})\}.$$

この $g_t$ は $\mathrm{OBJ}(p) = \mathrm{ANF}(p)$ の $p_t$ における優勾配である．

**証明**．各ペアについて，選んだ最小カットは $p_t$ で一致するアフィン上界を与える． その不等式を全ペアで平均すると

$$\mathrm{OBJ}(u) \leq \mathrm{OBJ}(p_t) + \langle g_t, u - p_t \rangle \qquad (u \in \Delta_E). \quad \square$$

$g_{t,e}$ は，選んだ最小カットに辺 $e$ が現れる割合．

# 4-2．ANFでは頂点対を一つ抽出できる

**補題4.3**．ANFの最適応答を構成するカット族から，一つのペア $(s, r)$ を一様に抽出する．

$$\hat{g}_{t,e} = \mathbf{1}\{e \in \delta^+(S_{sr}^{(t)})\}, \qquad \mathbb{E}[\hat{g}_t \mid \mathcal{H}_t] = g_t.$$

**証明**．各ペアの抽出確率は $1/[n(n-1)]$．条件付き期待値は補題4.2の平均に一致する．□

$\mathcal{H}_t$ は抽出前までの履歴を表す．

$$p_{t+1,e} = \frac{p_{t,e}\exp(\eta \hat{g}_{t,e})}{\sum_f p_{t,f}\exp(\eta \hat{g}_{t,f})}.$$

抽出したペアの最小カットを計算するので，最大流計算は **1回**．
抽出した一つのカットは，ANF全体の優勾配とは限らない．期待値で一致する．

# 4-2．Global mincutを最大流計算で求める

**手順**．基準となる頂点 $r$ を一つ選ぶ．

1. 各 $v \neq r$ について，$r$ **から** $v$ と $v$ **から** $r$ の最大流を計算する．
2. 得られた $2(n-1)$ 個の値から最小値を選び，対応する最小カットを返す．

この手順が正しいのは，任意の基準頂点 $r$ に対して次が成り立つため：

$$\kappa_{\mathrm{glob}}(x) = \min_{v \neq r} \min\{\kappa_{rv}(x), \kappa_{vr}(x)\}.$$

**証明**．右辺のどの $s$–$t$ カットもglobal mincutの候補なので，右辺 $\geq \kappa_{\mathrm{glob}}(x)$． 逆向きには，global mincutを与える集合 $S^\star$ を考える．

- $r \in S^\star$ なら，$v \notin S^\star$ を選ぶ．$S^\star$ は $r$–$v$ カットだから $\kappa_{rv}(x) \leq c_x(S^\star) = \kappa_{\mathrm{glob}}(x)$．
- $r \notin S^\star$ なら，$v \in S^\star$ を選ぶ．$S^\star$ は $v$–$r$ カットだから $\kappa_{vr}(x) \leq c_x(S^\star) = \kappa_{\mathrm{glob}}(x)$．

どちらの場合も，計算した値の中に $\kappa_{\mathrm{glob}}(x)$ が現れる．□

# 4-2．1反復の計算量を比較する

最大流・最小カット1回の時間を $T_{\text{flow}}$ とする．

| 方法 | 最大流の回数 | 1反復の時間（単純実装） |
|---|---|---|
| Global mincut | $2(n-1)$ | $O(n(T_{\text{flow}}+m))$ |
| ANF：全ペア | $n(n-1)$ | $O(n^2(T_{\text{flow}}+m))$ |
| ANF：1ペア抽出 | $1$ | $O(T_{\text{flow}}+m)$ |

# 4-3．加法誤差の収束保証

**定理4.4**．$\mathrm{OBJ}(p) = \mathrm{ANF}(p)$ または $\kappa_{\mathrm{glob}}(p)$ とする． 履歴 $\mathcal{H}_t$ に対して，更新に使う $\hat{g}_t$ が

$$0 \le \hat{g}_{t,e} \le 1, \qquad \mathbb{E}[\hat{g}_t \mid \mathcal{H}_t] \in \partial^{+}\mathrm{OBJ}(p_t)$$

を満たすと仮定する．$p_{1,e} = 1/m$，$\eta = \sqrt{2\log m / T}$ とし，$p_{t+1,e} \propto p_{t,e}\exp(\eta \hat{g}_{t,e})$ で $T \ge 1$ 回更新すると

$$\boxed{\mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \ge \mathrm{OPT} - \sqrt{\frac{2\log m}{T}}}, \qquad \bar{p}_T = \frac{1}{T}\sum_{t=1}^{T} p_t.$$

加法精度 $\delta > 0$ には $T \ge \lceil 2\log m / \delta^2 \rceil$ で十分． 期待値は，アルゴリズムの全反復の内部乱数について取る．

## 4-3．定理4.4の証明

最適配分 $p^\star$ を一つ固定する．不偏性と優勾配不等式により

$$\mathrm{OPT} - \mathrm{OBJ}(p_t) \le \langle \mathbb{E}[\hat{g}_t \mid \mathcal{H}_t], p^\star - p_t \rangle = \mathbb{E}[\langle \hat{g}_t, p^\star - p_t \rangle \mid \mathcal{H}_t].$$

期待値を取り，$t = 1, \dots, T$ について足す．補題2.2は各実現値に成り立つので

$$T\mathrm{OPT} - \sum_{t} \mathbb{E}[\mathrm{OBJ}(p_t)] \le \mathbb{E}[\mathrm{Reg}_T(p^\star)] \le \frac{\log m}{\eta} + \frac{\eta T}{2}.$$

凹性 $\mathrm{OBJ}(\bar{p}_T) \ge T^{-1}\sum_t \mathrm{OBJ}(p_t)$ を用いると

$$\mathrm{OPT} - \mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \le \frac{\log m}{\eta T} + \frac{\eta}{2}.$$

$\eta = \sqrt{2\log m / T}$ を代入して結論を得る．$\square$

# 4-3．目的値の尺度と加法精度

**補題4.5**．任意の非負容量 $x$ に対し

$$\kappa_{\mathrm{glob}}(x) \le \frac{1}{n}\sum_{e} x_e, \qquad \mathrm{ANF}(x) \le \frac{1}{n}\sum_{e} x_e.$$

**証明**．$d^+_x(s) = \sum_{e\in\delta^+(\{s\})} x_e$ とすると $\kappa_{sr}(x) \le d^+_x(s)$．ペアについて最小化・平均化して

$$\kappa_{\mathrm{glob}}(x) \le \min_s d^+_x(s) \le \frac{1}{n}\sum_{s} d^+_x(s), \qquad \mathrm{ANF}(x) \le \frac{1}{n}\sum_{s} d^+_x(s) = \frac{1}{n}\sum_{e} x_e.$$

総容量が $1$ なので $\mathrm{OPT} \le 1/n$．$k>0$，$\delta = k/n$ とすると，定理4.4から $T = O(n^2 \log m/k^2)$ で期待値の加法精度 $\delta$ を得る．$\square$

# 4-3．期待値での相対近似

**系4.6**．定理4.4の設定で，global mincutの最小カット，ANFの全ペア平均， またはANFの1ペア抽出を用いる．$p_{1,e} = 1/m$，$0 < \eta \le 1/2$ とすると

$$\mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \ge (1-\eta)\mathrm{OPT} - \frac{\log m}{\eta T}.$$

$0 < \varepsilon < 1$，既知の $0 < \gamma \le \mathrm{OPT}$ について

$$\eta = \varepsilon/2, \qquad T \ge \left\lceil \frac{4\log m}{\varepsilon^2 \gamma} \right\rceil$$

と選べば

$$\mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \ge (1-\varepsilon)\mathrm{OPT}.$$

# 4-3．系4.6の証明（1）

まず，更新に使うカットの係数と現在の配分との内積を計算する．

**Global mincut**．$S_t$ が現在の最小カットなので

$$\langle p_t, g_t \rangle = \sum_{e \in \delta^+(S_t)} p_{t,e} = \kappa_{\mathrm{glob}}(p_t) = \mathrm{OBJ}(p_t).$$

**ANFの全ペア平均**．各 $S_{sr}^{(t)}$ が $(s, r)$ の最小カットなので

$$\langle p_t, g_t \rangle = \frac{1}{n(n-1)} \sum_{s \neq r} \sum_{e \in \delta^+(S_{sr}^{(t)})} p_{t,e} = \frac{1}{n(n-1)} \sum_{s \neq r} \kappa_{sr}(p_t) = \mathrm{OBJ}(p_t).$$

**ANFの1ペア抽出**．$p_t$ は履歴 $\mathcal{H}_t$ から決まり，$\mathbb{E}[\hat{g}_t \mid \mathcal{H}_t] = g_t$ より

$$\mathbb{E}[\langle p_t, \hat{g}_t \rangle \mid \mathcal{H}_t] = \langle p_t, g_t \rangle = \mathrm{OBJ}(p_t).$$

従って，どの方法でもこの条件付き期待値の等式が成り立つ．

# 4-3．系4.6の証明（2）

$D_t = D_{\mathrm{KL}}(u\|p_t)$，$Z_t = \sum_e p_{t,e} e^{\eta \widehat{g}_{t,e}}$ とおく．$0 \le \eta \widehat{g}_{t,e} \le 1/2$ では $e^z \le 1 + z + z^2$ なので

$$\begin{aligned}\log Z_t &\le \log\left(1 + \eta\langle p_t, \widehat{g}_t\rangle + \eta^2 \langle p_t, \widehat{g}_t^{\,2}\rangle\right)\\ &\le \eta\langle p_t, \widehat{g}_t\rangle + \eta^2\langle p_t, \widehat{g}_t^{\,2}\rangle \le (\eta + \eta^2)\langle p_t, \widehat{g}_t\rangle.\end{aligned}$$

最後は $0 \le \widehat{g}_{t,e} \le 1$ から $\widehat{g}_{t,e}^2 \le \widehat{g}_{t,e}$ を用いた．KLの差 $D_t - D_{t+1} = \eta\langle u, \widehat{g}_t\rangle - \log Z_t$ に代入すると

$$\langle u - p_t, \widehat{g}_t\rangle \le \frac{D_t - D_{t+1}}{\eta} + \eta\langle p_t, \widehat{g}_t\rangle.$$

$t$ について足し，$D_1 \le \log m$，$D_{T+1} \ge 0$ を使えば

$$\mathrm{Reg}_T(u) \le \frac{\log m}{\eta} + \eta \sum_t \langle p_t, \widehat{g}_t\rangle.$$

# 4-3．系4.6の証明（3）

$u = p^\star$ を最適配分とする．優勾配不等式に期待値を取り，前2枚の結果を使うと

$$T\mathrm{OPT} - \sum_{t} \mathbb{E}[\mathrm{OBJ}(p_t)] \le \mathbb{E}[\mathrm{Reg}_T(p^\star)] \le \frac{\log m}{\eta} + \eta \sum_{t} \mathbb{E}[\mathrm{OBJ}(p_t)].$$

移項して $T(1+\eta)$ で割り，凹性を用いる．$B = \log m / (\eta T)$ とおくと

$$\mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \ge \frac{1}{T}\sum_{t} \mathbb{E}[\mathrm{OBJ}(p_t)] \ge \frac{\mathrm{OPT} - B}{1+\eta} \ge (1-\eta)\mathrm{OPT} - B.$$

最後の不等式は，両辺の差が $(\eta^2 \mathrm{OPT} + \eta B)/(1+\eta) \ge 0$ だから成り立つ．$\eta = \varepsilon/2$，$T \ge 4\log m/(\varepsilon^2 \gamma)$ なら

$$B \le \frac{\varepsilon \gamma}{2} \le \frac{\varepsilon \mathrm{OPT}}{2}.$$

従って

$$\mathbb{E}[\mathrm{OBJ}(\bar{p}_T)] \ge (1-\varepsilon/2)\mathrm{OPT} - \varepsilon\mathrm{OPT}/2 = (1-\varepsilon)\mathrm{OPT}. \quad \square$$

# 4-4．強連結グラフのOPTのオーダー

$\mathrm{OPT}_{\mathrm{cut}} = \max_p \kappa_{\mathrm{glob}}(p)$，$\mathrm{OPT}_{\mathrm{ANF}} = \max_p \mathrm{ANF}(p)$ とおく．

**命題4.7**．$n \geq 2$ の強連結な有向グラフでは

$$\frac{1}{2(n-1)} \leq \mathrm{OPT}_{\mathrm{cut}} \leq \mathrm{OPT}_{\mathrm{ANF}} \leq \frac{1}{n}.$$

従って，辺数によらず，どちらの最適値も $\Theta(1/n)$ である．

**証明**．根 $r$ を固定し，$r$ から全頂点へ向かう有向全域木と，全頂点から $r$ へ向かう 有向全域木を取る．各木の辺数は $n-1$，和集合 $H$ の辺数は $k \leq 2(n-1)$．

$H$ では任意の $u, v$ について $u \to r \to v$ と進めるので，$H$ は強連結． その各辺に容量 $1/k$ を配ると，全ての $\emptyset \neq S \subsetneq V$ について

$$\delta_H^+(S) \neq \emptyset \quad \Longrightarrow \quad c_p(S) \geq \frac{1}{k} \geq \frac{1}{2(n-1)}.$$

これがglobal mincutの下界を与える．全ペアの最小値は平均以下なので $\kappa_{\mathrm{glob}}(p) \leq \mathrm{ANF}(p)$．最後の上界は補題4.5による．□

## 4-4．強連結でない場合のOPT

**命題4.8**．自己ループのない有向グラフで $n \geq 2$，$E \neq \emptyset$ とする．

$$\frac{1}{n(n-1)} \leq \mathrm{OPT}_{\mathrm{ANF}} \leq \frac{1}{n}.$$

また，グラフが強連結でなければ $\mathrm{OPT}_{\mathrm{cut}} = 0$ である．

**証明**．1本の辺 $u \to v$ に全容量を配れば $\kappa_{uv} \geq 1$ となるので，ANFの下界を得る． 上界は補題4.5．強連結でない場合，強連結成分を縮約したDAGの終点成分 $S$ は $\emptyset \neq S \subsetneq V$，$\delta^+(S) = \emptyset$ を満たし，全配分で $c_p(S) = 0$．$\square$

ANFの下界を達成する例は，中心 $r$ から各葉への辺だけを持つ**外向きスター**である． 到達可能な順序付き頂点対は $(r, v)$ だけなので，任意の配分について

$$\mathrm{ANF}(p) = \frac{1}{n(n-1)} \sum_{v \neq r} p_{rv} = \frac{1}{n(n-1)} = \Theta(n^{-2}).$$

この例は，向きを無視すると連結であっても，ANFの最適値が $\Theta(1/n)$ とは限らないことを示す．

# 4-4．代表的なグラフと反復数

総容量は $1$，$n \geq 3$ とする．双方向スターは，各葉と中心を両方向の辺で結ぶ．

| 有向グラフ | $\mathrm{OPT}_{\mathrm{cut}}$ | $\mathrm{OPT}_{\mathrm{ANF}}$ |
|---|---|---|
| 有向サイクル | $1/n$ | $1/n$ |
| 双方向スター | $1/[2(n-1)]$ | $1/[2(n-1)]$ |
| 外向きスター | $0$ | $1/[n(n-1)]$ |
| 有向パス $1 \to 2 \to \cdots \to n$ | $0$ | $1/[2(n-1)]$ |

サイクルは各辺への容量 $1/n$ で上界を達成する．残る2例の計算は次頁で示す．

系4.6に下界を代入すると，期待値での相対精度に十分な反復数は

$$T = \begin{cases} O(n \log m/\varepsilon^2), & \text{強連結：両指標,} \\ O(n^2 \log m/\varepsilon^2), & \text{一般の非空グラフ：ANF.} \end{cases}$$

## 4-4．代表例のOPTの証明

**双方向スター**．葉 $i$ から中心への容量を $a_i$，逆向きを $b_i$ とする．$\sum_i (a_i + b_i) = 1$ で，葉の単点カットとその補集合からglobal mincutは $\min_i \{a_i, b_i\}$ 以下． ANFについては，中心と葉の間の流量の和が $1$ なので

$$\sum_{s \neq t} \kappa_{st} = 1 + \sum_{i \neq j} \min(a_i, b_j) \leq 1 + \frac{1}{2} \sum_{i \neq j} (a_i + b_j) = \frac{n}{2}.$$

両指標とも $1/[2(n-1)]$ 以下であり，全 $2(n-1)$ 辺への一様配分で等号を達成する．

**有向パス**．辺 $i \to i+1$ の容量を $p_i$ とすると，$i < j$ では $\kappa_{ij} = \min_{i \leq k < j} p_k \leq (p_i + p_{j-1})/2$，逆方向の流量は $0$．従って

$$\sum_{i<j} \kappa_{ij} \leq \frac{1}{2} \sum_{k=1}^{n-1} \big((n-k) + k\big) p_k = \frac{n}{2}, \qquad \mathrm{ANF}(p) \leq \frac{1}{2(n-1)}.$$

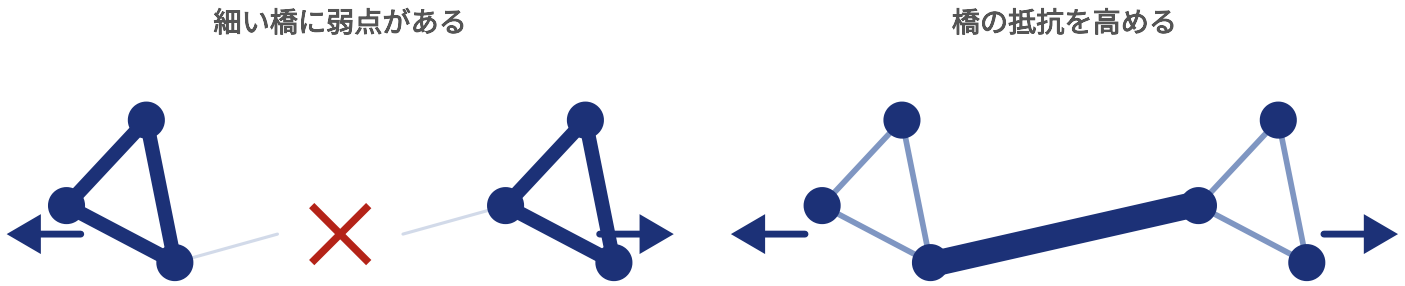
全辺に $1/(n-1)$ を配ると，到達可能な $n(n-1)/2$ ペアの流量が全て $1/(n-1)$ となり，等号を達成する．$\square$

# 5．Algebraic connectivity 最大化

# 5-1．ネットワーク設計と重み配分

通信網の耐障害性，交通・物流網の機能維持，分散システムの情報共有では， ネットワークの連結性が重要になる．

与えられたグラフの各辺に総量 1 の重みを配分し，連結性を最大化したい．




同じ構造でも，辺への重み配分によって，弱い接続への抵抗は変わる．

# 5-1．無向グラフのラプラシアン

辺 $e = \{u, v\}$ に対し $b_e = \chi_u - \chi_v$ とおく．

$$L(w) = \sum_{e \in E} w_e b_e b_e^\top, \qquad x^\top L(w) x = \sum_{\{u,v\} \in E} w_{uv} (x_u - x_v)^2.$$

- $L(w)$ は対称・半正定値で，$L(w)\mathbf{1} = 0$．
- 固有値を $0 = \lambda_1 \le \lambda_2 \le \cdots \le \lambda_n$ と並べる．
- **Algebraic connectivity（AC）** は $\lambda_2(L(w))$．
- $\lambda_2 > 0$ と，正の重みを持つ辺からなるグラフの連結性は同値．

Fiedler 1973．本資料は非正規化ラプラシアンを用いる．

# 5-1．Algebraic Connectivity

$$X = \{x \in \mathbb{R}^n : x^\top \mathbf{1} = 0,\ \|x\|_2 = 1\}, \qquad \lambda_2(L(w)) = \min_{x \in X} \sum_{\{u,v\}} w_{uv}(x_u - x_v)^2.$$

- 守備側は総量 1 のばね定数 $w_e$ を辺へ配分する．
- 攻撃側は頂点の**変位** $x_u$ を選ぶ．符号が向き，絶対値が大きさを表す．
- $x \perp \mathbf{1}$ で全体の平行移動を除き，$\|x\|_2 = 1$ で大きさを揃える．
- 攻撃側は最もエネルギーが小さい変形を選ぶ．その最適応答が **Fiedlerベクトル**．

> $C(x; w) = x^\top L(w) x$ を変形のコストと考える．ACはその最小値である．

$$\max_{w \in \Delta_E} \min_{x \in X} \sum_{\{u,v\}} w_{uv}(x_u - x_v)^2.$$

# 5-1．例：中央の橋を強める効果

パス $1$-$2$-$3$-$4$ に $x = (-1/2, -1/2, 1/2, 1/2)$ を与える．

**守備A：橋 $\{2,3\}$ が細い**

同じ引っ張り → コスト小（攻撃有利）

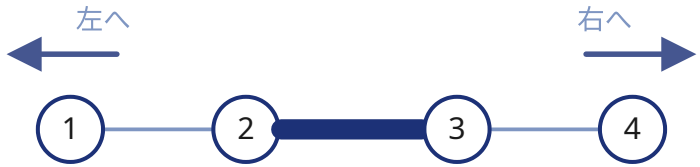



$w_{12} = w_{34} = 0.45,\ w_{23} = 0.10$

$C = w_{23} = 0.10$

**守備B：橋 $\{2,3\}$ が太い**

同じ引っ張り → コスト大（守備有利）




$w_{12} = w_{34} = 0.05,\ w_{23} = 0.90$

$C = w_{23} = 0.90$

$$x^\top L(w) x = w_{23}.$$

この変形への抵抗は中央の重みで増える．ACは**全ての変形の最小値**なので，別の弱点への移動も考慮する．

# 5-1．Absolute Algebraic Connectivity

**定義5.1**．連結な無向グラフ $G = (V, E)$ に対して

$$\mathrm{OPT} := \max_{w \in \Delta_E} \lambda_2(L(w)), \qquad \Delta_E = \left\{ w \in \mathbb{R}^E_{\geq 0} : \sum_e w_e = 1 \right\}$$

を **Absolute Algebraic Connectivity（AAC）** と呼ぶ．

守備側は，攻撃側が最も変形しやすい方向を選ぶことを見越して，重みを配分する：

$$\max_{w \in \Delta_E} \min_{x \in X} x^\top L(w) x.$$

$0 < \varepsilon < 1$ に対し，$\bar{w} \in \Delta_E$ が

$$\lambda_2(L(\bar{w})) \geq (1 - \varepsilon)\mathrm{OPT}$$

を満たすとき，$\bar{w}$ を $(1-\varepsilon)$**-近似解** という．

Fiedler (1990).

# 5-2．Fiedlerベクトルが優勾配を与える

**補題5.2**．$x_t \in X$ を現在の $L(w_t)$ のFiedlerベクトルとする．

$$\boxed{g_{t,\{a,b\}} = (x_{t,a} - x_{t,b})^2}$$

は $\mathrm{OBJ}(w) = \lambda_2(L(w))$ の $w_t$ における優勾配である．

**証明**．任意の $u \in \Delta_E$ に対し

$$\mathrm{OBJ}(u) \le x_t^\top L(u) x_t = \langle g_t, u \rangle = \mathrm{OBJ}(w_t) + \langle g_t, u - w_t \rangle. \quad \square$$

- $\lambda_2$ が単純なら，これが通常の勾配．
- 重複固有値でも，$X$ 内の対応固有ベクトルを一つ選べばよい．

# 5-2．勾配の範囲と更新式

**補題5.3**．$x_t \in X$ なら $0 \le g_{t,e} \le 2$．

**証明**．$\|x_t\|_2 = 1$ より，各辺で

$$0 \le (x_{t,a} - x_{t,b})^2 \le 2(x_{t,a}^2 + x_{t,b}^2) \le 2.$$

利得を $\ell_{t,e} = g_{t,e}/4$ とおくと $0 \le \ell_{t,e} \le 1$．更新式は

$$w_{t+1,e} \propto w_{t,e} \exp\left(\frac{\eta}{4}(x_{t,a} - x_{t,b})^2\right).$$

最適な攻撃（変形）に対し，大きく伸びる辺へ相対的に重みを配る．

# 5-2．近似Fiedlerベクトルの定義

**定義5.4**．$\alpha \geq 0$ とする．ラプラシアン $L(w)$ に対し

$$x \in X = \{x \in \mathbb{R}^n : x^\top \mathbf{1} = 0,\ \|x\|_2 = 1\}, \qquad x^\top L(w) x \leq (1+\alpha)\lambda_2(L(w))$$

を満たす $x$ を **$\alpha$-近似Fiedlerベクトル** と呼ぶ．

Rayleigh商の最小値が $\lambda_2$ なので，$q = x^\top L(w) x$ は

$$\lambda_2(L(w)) \leq q \leq (1+\alpha)\lambda_2(L(w))$$

を満たす．ここで近似するのは **Rayleigh商の値** である．

出典：Spielman–Teng (2014), Definition 7.1・Theorem 7.2.

# 5-2．近似Fiedlerベクトルの高速計算

**引用定理5.5**．Spielman–Teng (2014), Theorem 7.2より，$0 < \alpha < 1$，$0 < \rho < 1$ に対し，重み付き連結グラフの $\alpha$-近似Fiedlerベクトルを確率 $1 - \rho$ 以上で出力する乱択アルゴリズムがある．

$$O\left( m \log^{c} m \, \log(1/\rho) \, \frac{\log(2/\alpha)}{\alpha} \right) = \widetilde{O}\left( \frac{m}{\alpha} \log \frac{1}{\rho} \right).$$

- ラプラシアンの線形方程式を高速に解き，逆べき乗法を実行する．
- 独立な試行から，Rayleigh商が最も小さい出力を選ぶ．
- $\rho = m^{-10}$ なら，1回の時間は $\widetilde{O}(m/\alpha)$．
- ACのアルゴリズムで用いる乱数は，このオラクルに由来する．

出典：Spielman–Teng (2014)．$\widetilde{O}$ は対数因子を省略する．

## 5-2．アルゴリズム$A_1$

**入力**：連結な無向グラフ，$\alpha > 0$，$0 < \eta \le 1/2$，反復数 $T$． **出力**：辺重み $\bar{w}_T \in \Delta_E$．

1. 各辺で $w_{1,e} = 1/m$ とする．
2. $t = 1, \dots, T$ に対して次を繰り返す．

   $L(w_t)$ の $\alpha$-近似Fiedlerベクトル $x_t \in X$ を求める． 各辺 $e = \{u, v\}$ の利得を

   $$\ell_{t,e} = \frac{(x_{t,u} - x_{t,v})^2}{4}$$

   とし，指数更新する：

   $$w_{t+1,e} = \frac{w_{t,e} \exp(\eta \ell_{t,e})}{\sum_f w_{t,f} \exp(\eta \ell_{t,f})}.$$

3. $\bar{w}_T = \dfrac{1}{T} \displaystyle\sum_{t=1}^{T} w_t$ を返す．

各回で現在の弱い変形を求め，その変形に対する係数が大きい辺へ重みを配る．

# 5-3．Local norm technique

通常の加法リグレット評価から相対精度を得るには，誤差を $\varepsilon\mathrm{OPT}$ 以下にする必要がある．

$$T = O\left(\frac{\log m}{\varepsilon^2 \mathrm{OPT}^2}\right).$$

解析の二次項を，重み付きの量

$$\|\ell_t\|_{w_t}^2 := \sum_e w_{t,e}\ell_{t,e}^2 \le \sum_e w_{t,e}\ell_{t,e} = \langle w_t, \ell_t\rangle$$

で評価すると，反復数を

$$T = O\left(\frac{\log m}{\varepsilon^2 \mathrm{OPT}}\right)$$

に改善できる．

Shalev-Shwartz (2012), “Online Learning and Online Convex Optimization”.

# 5-3．Local normによる利得の評価

**補題5.6**．$\ell_t \in [0,1]^E$，$w_{1,e} = 1/m$，$0 < \eta \le 1/2$ とする．指数更新 $w_{t+1,e} \propto w_{t,e} e^{\eta \ell_{t,e}}$ に対し，任意の $u \in \Delta_E$ について

$$\sum_{t} \langle w_t, \ell_t \rangle \ge (1-\eta) \sum_{t} \langle u, \ell_t \rangle - \frac{\log m}{\eta}.$$

**証明**．$D_t = D_{\mathrm{KL}}(u \| w_t)$ とする．系4.6の証明（2）と同じ指数の評価より

$$\langle u - w_t, \ell_t \rangle \le \frac{D_t - D_{t+1}}{\eta} + \eta \langle w_t, \ell_t \rangle.$$

$A = \sum_t \langle w_t, \ell_t \rangle$，$B = \sum_t \langle u, \ell_t \rangle$，$b = \log m / \eta$ とおく．足し合わせ，$D_1 \le \log m$，$D_{T+1} \ge 0$ を使うと $B - A \le b + \eta A$．従って

$$A \ge \frac{B - b}{1+\eta} \ge (1-\eta) B - b.$$

最後の両辺の差は $(\eta^2 B + \eta b)/(1+\eta) \ge 0$ である．$\square$

# 5-3．近似Fiedlerベクトルによる保証

**定理5.7**．アルゴリズム$\mathrm{A}_1$で$\alpha > 0$，$0 < \eta \leq 1/2$，$T \geq 1$とする． 全$T$回で$\alpha$-近似Fiedlerベクトルが得られれば，出力は

$$\mathrm{OBJ}(\bar{w}_T) = \lambda_2(L(\bar{w}_T)) \geq \frac{(1-\eta)\mathrm{OPT} - 4\log m/(\eta T)}{1+\alpha}$$

を満たす．

各回の条件付き失敗確率が$\rho$以下なら，この保証の成功確率は$1 - T\rho$以上． 特に$\rho = m^{-10}$なら

$$\Pr\left[\mathrm{OBJ}(\bar{w}_T) \geq \frac{(1-\eta)\mathrm{OPT} - 4\log m/(\eta T)}{1+\alpha}\right] \geq 1 - \frac{T}{m^{10}}.$$

$0 < \alpha < 1$のとき，1反復の時間は$\widetilde{O}(m/\alpha)$．

# 5-3．定理5.7の証明（1）

全ての近似オラクルが成功したとする． $q_t = x_t^\top L(w_t) x_t = 4\langle w_t, \ell_t \rangle$ とおく．

最適配分 $w^\star$ に対し，$x_t \in X$ より

$$\mathrm{OPT} = \min_{x \in X} x^\top L(w^\star) x \le x_t^\top L(w^\star) x_t = 4\langle w^\star, \ell_t \rangle.$$

補題5.6に $u = w^\star$ を代入すれば

$$\begin{aligned}
\sum_t q_t &= 4 \sum_t \langle w_t, \ell_t \rangle \\
&\ge 4(1-\eta) \sum_t \langle w^\star, \ell_t \rangle - \frac{4 \log m}{\eta} \\
&\ge (1-\eta) T \mathrm{OPT} - \frac{4 \log m}{\eta}.
\end{aligned}$$

従って，平均Rayleigh商は

$$\frac{1}{T} \sum_t q_t \ge (1-\eta)\mathrm{OPT} - \frac{4 \log m}{\eta T}.$$

# 5-3．定理5.7の証明（2）

近似Fiedlerベクトルの定義より $q_t \le (1+\alpha)\mathrm{OBJ}(w_t)$．従って

$$\frac{1}{T}\sum_t \mathrm{OBJ}(w_t) \ge \frac{1}{1+\alpha}\frac{1}{T}\sum_t q_t \ge \frac{(1-\eta)\mathrm{OPT} - 4\log m/(\eta T)}{1+\alpha}.$$

$\mathrm{OBJ}$ は線形関数 $w \mapsto x^\top L(w) x$ の最小値なので凹関数．Jensenの不等式から

$$\mathrm{OBJ}(\bar{w}_T) = \mathrm{OBJ}\left(\frac{1}{T}\sum_t w_t\right) \ge \frac{1}{T}\sum_t \mathrm{OBJ}(w_t)$$

となり，目的値の保証を得る． 各時刻の失敗事象を $F_t$ とすると，条件付き保証とunion boundにより

$$\Pr\left[\bigcup_{t=1}^{T} F_t\right] \le \sum_{t=1}^{T} \mathbb{E}[\Pr(F_t \mid \mathcal{H}_t)] \le T\rho.$$

引用定理5.5と $O(m)$ 時間の更新から，1反復の計算量も得る．□

# 5-3．相対精度と成功確率

**系5.8**．$0 < \varepsilon, \beta < 1$，既知の $0 < \gamma \le \mathrm{OPT}$ に対し

$$\alpha = \eta = \varepsilon/4, \qquad T = \left\lceil \frac{64 \log m}{\varepsilon^2 \gamma} \right\rceil$$

と選ぶ．各回の条件付き失敗確率を $\rho \le \beta / T$ とすれば

$$\Pr[\mathrm{OBJ}(\bar{w}_T) \ge (1-\varepsilon)\mathrm{OPT}] \ge 1 - \beta.$$

**証明**．全回成功する確率は $1 - T\rho \ge 1 - \beta$．この事象上で

$$\frac{4 \log m}{\eta T} \le \frac{\varepsilon \gamma}{4} \le \frac{\varepsilon \mathrm{OPT}}{4}, \qquad \frac{1 - \varepsilon/2}{1 + \varepsilon/4} \ge 1 - \varepsilon.$$

定理5.7に代入すればよい．$\square$

$\gamma = \Theta(\mathrm{OPT})$ なら，総時間は $\widetilde{O}(m/(\varepsilon^3 \mathrm{OPT}))$．

## 5-3．最適値の範囲

**補題5.9**．連結な無向グラフのAACは

$$\frac{1}{n^3} \leq \mathrm{OPT} \leq \frac{2}{n-1}$$

を満たす．

**上界の証明**．$\sum_e w_e = 1$，$\mathrm{Tr}(b_e b_e^\top) = 2$ なので

$$\sum_{i=2}^{n} \lambda_i(L(w)) = \mathrm{Tr}(L(w)) = 2.$$

最小の非自明な固有値は，これら $n-1$ 個の平均以下だから

$$\lambda_2(L(w)) \leq \frac{1}{n-1} \sum_{i=2}^{n} \lambda_i(L(w)) = \frac{2}{n-1}.$$

どの配分でも成立するため，最大化した $\mathrm{OPT}$ にも同じ上界が成り立つ．

## 5-3．補題5.9の証明

全域木 $H$ の各辺に $1/(n-1)$ を配る．$x \in X$，$M = \max_i x_i$，$m_x = \min_i x_i$ とする．$(M - x_i)(x_i - m_x) \geq 0$ を平均し，$\sum_i x_i = 0$，$\sum_i x_i^2 = 1$ を使うと

$$\frac{1}{n} \leq -Mm_x \leq \frac{(M - m_x)^2}{4}.$$

最大・最小の頂点を結ぶ木の道を $P$ とすると，$|P| \leq n-1$．Cauchy–Schwarzより

$$\begin{aligned} x^\top L(w) x &\geq \frac{1}{n-1} \sum_{\{u,v\} \in P} (x_u - x_v)^2 \\ &\geq \frac{(M - m_x)^2}{(n-1)|P|} \geq \frac{4}{n(n-1)^2} \geq \frac{1}{n^3}. \end{aligned}$$

全ての $x \in X$ について最小化すれば，この配分のACが $1/n^3$ 以上．従って，その最大値である $\mathrm{OPT}$ も $1/n^3$ 以上である．$\square$

## 5-3．直径によるOPTの下界

連結な無向グラフの直径を $D$ とすると，補題5.9の下界を

$$\mathrm{OPT} \geq \frac{2}{n(n-1)D}$$

と評価できる．特に，$D = O(1)$ なら $\mathrm{OPT} = \Omega(n^{-2})$ である．

**証明**．任意の頂点を根とする幅優先探索木 $H$ を取り，各木辺に $1/(n-1)$ を配る． 根からの深さは $D$ 以下なので，木上の任意の2頂点間の距離は $2D$ 以下．

$x \in X$ の最大値・最小値を $M, m_x$ とする．前頁と同様に $(M - m_x)^2 \geq 4/n$． この2頂点を結ぶ木の道 $P$ に沿って

$$x^\top L(w) x \geq \frac{(M-m_x)^2}{(n-1)|P|} \geq \frac{4/n}{2D(n-1)} = \frac{2}{n(n-1)D}.$$

$x \in X$ について最小化してもこの下界が残る．□

$D \leq n-1$ より常に $\Omega(n^{-3})$．次の例では，このオーダーから $\Theta(n^{-1})$ まで変化する．

# 5-3．代表的なグラフのOPTのオーダー

総重みは $1$，$n \geq 3$ とする．$\mathsf{A}_1$の総時間は $\widetilde{O}(m/(\varepsilon^3 \mathrm{OPT}))$．

| 無向グラフ | 辺数 $m$ | $\mathrm{OPT}$ | $\mathsf{A}_1$の総時間 |
|---|---|---|---|
| パス $P_n$ | $n-1$ | $\Theta(n^{-3})$ | $\widetilde{O}(n^4/\varepsilon^3)$ |
| サイクル $C_n$ | $n$ | $\dfrac{2-2\cos(2\pi/n)}{n} = \Theta(n^{-3})$ | $\widetilde{O}(n^4/\varepsilon^3)$ |
| スター $K_{1,n-1}$ | $n-1$ | $\dfrac{1}{n-1} = \Theta(n^{-1})$ | $\widetilde{O}(n^2/\varepsilon^3)$ |
| 完全グラフ $K_n$ | $n(n-1)/2$ | $\dfrac{2}{n-1} = \Theta(n^{-1})$ | $\widetilde{O}(n^3/\varepsilon^3)$ |

パスとスターは同じ辺数だが，OPTのオーダーは $n^2$ 倍異なる．

一般の連結グラフでは $1/n^3 \leq \mathrm{OPT} \leq 2/(n-1)$．相対精度に十分な反復数 $T = O(\log m/(\varepsilon^2 \mathrm{OPT}))$ は，最悪の場合 $O(n^3 \log m/\varepsilon^2)$ となる．

## 5-3．パスのOPTの証明

頂点を $1,\dots,n$ と並べ，どの配分 $w$ にも同じ変位ベクトルを使う：

$$a_i = i - \frac{n+1}{2}, \qquad S = \sum_{i=1}^{n} a_i^2 = \frac{n(n^2-1)}{12}, \qquad x_i = \frac{a_i}{\sqrt{S}}.$$

$\sum_i x_i = 0$，$\|x\|_2 = 1$ より $x \in X$．隣接頂点の差は全て $1/\sqrt{S}$ なので

$$\lambda_2(L(w)) \le x^{\top} L(w) x = \sum_{i=1}^{n-1} w_{i,i+1} \frac{1}{S} = \frac{12}{n(n^2-1)}.$$

全ての $w \in \Delta_E$ に対する上界なので，最大化しても同じ上界が残る．一方，補題5.9の証明による下界を合わせると

$$\frac{4}{n(n-1)^2} \le \mathrm{OPT}(P_n) \le \frac{12}{n(n^2-1)}.$$

両端とも $\Theta(n^{-3})$ であり，$\mathrm{OPT}(P_n) = \Theta(n^{-3})$ を得る．$\square$

## 5-3．対称なグラフのOPTの証明

サイクル・スター・完全グラフでは，任意の2辺を移し合うグラフの自己同型が存在する． 自己同型の集合を $\Gamma$，$\sigma$ で並べ替えた配分を $w^\sigma$ とすると，その平均は一様配分：

$$\bar{w} = \frac{1}{|\Gamma|}\sum_{\sigma\in\Gamma} w^\sigma = \left(\frac{1}{m},\dots,\frac{1}{m}\right).$$

$F(w)=\lambda_2(L(w))$ は凹関数で，頂点の並べ替えによって変わらない．従って

$$F(\bar{w}) \geq \frac{1}{|\Gamma|}\sum_{\sigma\in\Gamma} F(w^\sigma) = F(w).$$

よって一様配分が最適．各辺の重みが 1 のラプラシアンを $L_G$ とすると，$\mathrm{OPT} = \lambda_2(L_G)/m$．

| | |
|---|---|
| グラフ | $L_G$ の固有値から求める $\lambda_2(L_G)$ |
| サイクル | Fourierモードの固有値 $2-2\cos(2\pi k/n)$ より $2-2\cos(2\pi/n)$ |
| スター | 固有値は $0, 1$（$n-2$ 個），$n$．従って $\lambda_2 = 1$ |
| 完全グラフ | $L_G = nI - \mathbf{1}\mathbf{1}^\top$ より $\lambda_2 = n$ |

それぞれ辺数で割れば表の値を得る．$1-\cos z = \Theta(z^2)$ より，サイクルは $\Theta(n^{-3})$．$\square$

# 5-3．未知のOPT：Doubling Trick

**定理5.10**．$0 < \varepsilon < 1$，$\eta = \alpha = \varepsilon/8$ とする． $\mathsf{A}_1$の反復を続け，$T = 1, 2, 4, 8, \ldots$ の時点で

$$U_T = \max_e \frac{1}{T} \sum_t g_{t,e}, \qquad L_T = \frac{q(\bar{w}_T)}{1+\alpha}, \qquad g_t = 4\ell_t$$

を計算する．$q(\bar{w}_T)$ も $\alpha$-近似Fiedlerベクトルで評価する．

$$L_T \geq (1-\varepsilon) U_T$$

を初めて満たした時点で停止する．全オラクルが成功する事象上で

$$\mathrm{OBJ}(\bar{w}_T) \geq (1-\varepsilon)\mathrm{OPT}, \qquad T = O\left(\frac{\log m}{\varepsilon^2 \mathrm{OPT}}\right).$$

反復数を2倍ずつ増やすことで，未知の $\mathrm{OPT}$ に応じた計算時間で停止できる．

# 5-3．定理5.10の証明（1）

近似条件より，出力のRayleigh商は

$$\mathrm{OBJ}(\bar{w}_T) \le q(\bar{w}_T) \le (1+\alpha)\mathrm{OBJ}(\bar{w}_T).$$

従って $L_T \le \mathrm{OBJ}(\bar{w}_T) \le \mathrm{OPT}$．一方，全ての $u \in \Delta_E$ に対し

$$\mathrm{OBJ}(u) \le \langle g_t, u \rangle \quad \Longrightarrow \quad \mathrm{OBJ}(u) \le \left\langle \frac{1}{T}\sum_t g_t, u \right\rangle \le U_T.$$

最大化すると $\mathrm{OPT} \le U_T$．よって，停止したときは

$$\mathrm{OBJ}(\bar{w}_T) \ge L_T \ge (1-\varepsilon)U_T \ge (1-\varepsilon)\mathrm{OPT}.$$

次に停止までの反復数を評価する．補題5.6の証明中の $B - A \le b + \eta A$ を各単体の頂点に使うと

$$U_T \le (1+\eta)\frac{1}{T}\sum_t q_t + B_T, \qquad B_T = \frac{4\log m}{\eta T}.$$

# 5-3．定理5.10の証明（2）

近似条件，凹性，$\mathrm{OBJ}(\bar{w}_T) \le (1+\alpha)L_T$ から

$$\begin{aligned}\mathrm{OPT} \le U_T &\le (1+\eta)\frac{1}{T}\sum_t q_t + B_T \\ &\le (1+\eta)(1+\alpha)\mathrm{OBJ}(\bar{w}_T) + B_T \le AL_T + B_T,\end{aligned}$$

ただし $A = (1+\eta)(1+\alpha)^2 = (1+\varepsilon/8)^3 \le 1+\varepsilon/2$.

$$T \ge \frac{256\log m}{\varepsilon^2 \mathrm{OPT}} \quad\Longrightarrow\quad B_T \le \frac{\varepsilon \mathrm{OPT}}{8}, \qquad L_T \ge \frac{\mathrm{OPT}-B_T}{A} \ge \frac{7}{12}\mathrm{OPT}.$$

従って $B_T/L_T \le 3\varepsilon/14$ であり

$$U_T \le (1+5\varepsilon/7)L_T \quad\Longrightarrow\quad (1-\varepsilon)U_T \le L_T.$$

この閾値を超えた最初の2倍刻みの判定で停止する．反復数は閾値の高々2倍である．□

## 5-3．主結果

**定理5.11**．連結な無向グラフ $G=(V,E)$ と $0<\varepsilon<1$ に対し，確率少なくとも $2/3$ で，時間

$$\widetilde{O}\Big(\frac{m}{\varepsilon^3 \mathrm{OPT}}\Big)$$

以内に $(1-\varepsilon)$-近似解 $\bar{w}\in\Delta_E$ を出力するアルゴリズムが存在する．

$$\lambda_2(L(\bar{w}))\geq(1-\varepsilon)\mathrm{OPT}.$$

- **MWU**：辺重みを指数更新する．
- **近似Fiedlerオラクル**：現在の弱い変形を高速に求める．
- **Local norm technique**：反復数の $\mathrm{OPT}$ への依存を2乗から1乗に改善する．
- **Doubling Trick**：$\mathrm{OPT}$ を知らずに停止する．

## 5-3．定理5.11の証明

更新用と出力評価用の全呼び出しに通し番号 $j = 1, 2, \ldots$ を付け，条件付き失敗確率を $\rho_j = 1/[3j(j+1)]$ とする．

$$\Pr[\text{いずれかが失敗}] \le \sum_{j \ge 1} \rho_j = \frac{1}{3} \sum_{j \ge 1} \left( \frac{1}{j} - \frac{1}{j+1} \right) = \frac{1}{3}.$$

全呼び出しが成功すれば，定理5.10により

$$T = O\left( \frac{\log m}{\varepsilon^2 \mathrm{OPT}} \right)$$

で所望の近似解を得る．$\alpha = \varepsilon/8$ なので，1回のオラクル時間は $\widetilde{O}(m/\varepsilon)$．$O(m)$ の更新と $O(\log T)$ 回の出力評価を加えても

$$\widetilde{O}(Tm/\varepsilon) = \widetilde{O}\left( \frac{m}{\varepsilon^3 \mathrm{OPT}} \right). \quad \square$$

成功確率を $1 - \delta$ にするには $\rho_j = \delta/[j(j+1)]$ とし，時間の増加は $\log(1/\delta)$ の因子に収まる．

# 5-3．計算量の比較

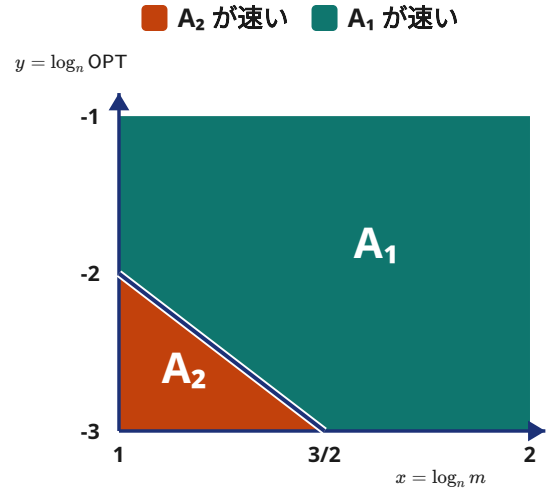
| 方法 | 計算量 |
|---|---|
| $A_1$：MWU | $\widetilde{O}(m/(\varepsilon^3 \mathrm{OPT}))$ |
| $A_2$：切除平面法 | $\widetilde{O}(m^3 \operatorname{polylog}(1/\varepsilon))$ |

$\varepsilon$ を定数とし，対数因子を省くと，境界は

$$\frac{m}{\mathrm{OPT}} = m^3 \quad \Longleftrightarrow \quad \mathrm{OPT} = m^{-2}.$$

- **パス** $P_n$：$m = \Theta(n)$，$\mathrm{OPT} = \Theta(n^{-3})$．$A_2$が有利．
- **直径** $O(1)$ **の密グラフ**：$m = \Theta(n^2)$，$\mathrm{OPT} = \Omega(n^{-2})$．$A_1$が有利．
- 完全グラフや密な完全二部グラフは後者の例．

切除平面法：Jiang–Lee–Song–Wong (2020).



## 5-3．まとめ

連結な無向グラフの辺へ総量 $1$ の重みを配分し，

$$\mathrm{OPT} = \max_{w \in \Delta_E} \lambda_2(L(w))$$

を近似する問題を考えた．

近似Fiedlerベクトルを応答に用いるMWUにより，確率 $2/3$ 以上で

$$\lambda_2(L(\bar{w})) \geq (1-\varepsilon)\mathrm{OPT}, \qquad \text{時間 } \widetilde{O}\Big(\frac{m}{\varepsilon^3 \mathrm{OPT}}\Big)$$

を達成する．

精度の解析はlocal normによる利得評価，未知の最適値への対応はDoubling Trickによる． 計算量の優劣は，辺数 $m$ と最適値 $\mathrm{OPT}$ の大きさに依存する．

# 3つの指標を同じ枠組みで見る

| | Global mincut | ANF | AC |
|---|---|---|---|
| グラフ | 有向 | 有向 | 無向 |
| 勾配の計算 | 全体の最小カット | 各ペアの最小カット | Fiedlerベクトル |
| $g_e$ | 指示関数 | 指示関数の平均 | $(x_u - x_v)^2$ |
| 更新に用いる正規化 $R$ | $1$ | $1$ | $4$ |
| 近似精度 | 期待値で加法保証 | 期待値で加法保証 | 近似固有ベクトルでも相対保証 |

> いずれも，凹な目的関数に対して単体上で指数更新する．
> ANFの抽出誤差と，ACの固有ベクトルの近似誤差を区別して扱う．

# 補足：証明と参考文献

必要に応じて参照

# 補足A．MWUの二次項評価

**補題A.1**．補題2.2の設定で $0 < \eta \le 1/2$ とする．全ての $u \in \Delta_E$ に対し

$$\boxed{\mathrm{Reg}_T(u) \le \frac{R \log m}{\eta} + \eta \sum_t \langle w_t, g_t \rangle}.$$

**証明**．$\ell_t = g_t / R$ とおく．$0 \le \eta \ell_{t,e} \le 1/2$ なので $e^z \le 1 + z + z^2$，$\log(1+a) \le a$ を使うと

$$\log \sum_e w_{t,e} e^{\eta \ell_{t,e}} \le \eta \langle w_t, \ell_t \rangle + \eta^2 \langle w_t, \ell_t^2 \rangle.$$

補題2.2の証明と同じKLの差に代入し，$\ell_{t,e}^2 \le \ell_{t,e}$ より

$$\langle u - w_t, g_t \rangle \le \frac{R}{\eta} \left[ D_{\mathrm{KL}}(u \| w_t) - D_{\mathrm{KL}}(u \| w_{t+1}) \right] + \eta \langle w_t, g_t \rangle.$$

足し合わせ，一様初期化のKL上界を用いればよい．$\square$

# 補足B．期待値での相対保証

**定理B.1**．$\mathrm{OBJ} \geq 0$ は単体上の連続な凹関数とする．一様初期化のMWUで，$0 < \eta \leq 1/2$，$0 \leq \hat{g}_{t,e} \leq R$，$\mathbb{E}[\hat{g}_t \mid \mathcal{H}_t] \in \partial^{+}\mathrm{OBJ}(w_t)$ および $\mathbb{E}[\langle w_t, \hat{g}_t \rangle \mid \mathcal{H}_t] \leq \mathrm{OBJ}(w_t)$ を仮定する．このとき

$$\mathbb{E}[\mathrm{OBJ}(\bar{w}_T)] \geq (1-\eta)\mathrm{OPT} - \frac{R \log m}{\eta T}.$$

**証明**．$w^{\star}$ を最適配分とする．定理4.4と同様に期待値を取り，補題A.1より

$$T\mathrm{OPT} - \sum_{t} \mathbb{E}[\mathrm{OBJ}(w_t)] \leq \mathbb{E}[\mathrm{Reg}_T(w^{\star})] \leq \frac{R \log m}{\eta} + \eta \sum_{t} \mathbb{E}[\mathrm{OBJ}(w_t)].$$

移項し，凹性と $1/(1+\eta) \geq 1-\eta$，$\mathrm{OPT} \geq 0$ を使うと

$$\mathbb{E}[\mathrm{OBJ}(\bar{w}_T)] \geq \frac{\mathrm{OPT} - R\log m/(\eta T)}{1+\eta} \geq (1-\eta)\mathrm{OPT} - \frac{R\log m}{\eta T}. \quad \square$$

# 補足C．内側を加法誤差で近似する場合

**命題C.1（加法誤差を持つオラクル）**．$\mathrm{OBJ}$ は単体上の連続な凹関数とする．補題2.2の初期化と更新を使い，$\eta = \sqrt{2\log m/T}$ とする．アフィン上界 $h_t(u) = b_t + \langle g_t, u\rangle$ が次を満たすとする：

$$\mathrm{OBJ}(u) \le h_t(u) \quad (\forall u), \qquad h_t(w_t) \le \mathrm{OBJ}(w_t) + \xi_t.$$

$g_t \in [0,R]^E$，$\xi_t \ge 0$ を仮定する．このとき $g_t$ は $\xi_t$-近似優勾配となり

$$\mathrm{OPT} - \mathrm{OBJ}(\bar{w}_T) \le R\sqrt{\frac{2\log m}{T}} + \frac{1}{T}\sum_t \xi_t.$$

反復を増やしても，内側の平均誤差は残る．高い精度にはオラクル精度の調整が必要．

**証明**．定理2.3の優勾配不等式に $\xi_t$ を加え，足し合わせる．□

# 補足D．添付ノートから補正した点

**ANFの上界**：正しくは $\mathrm{ANF}(x) \le \frac{1}{n}\sum_e x_e$．一般に $\mathrm{ANF}(x) \le \min_s d_x^+(s)$ ではない．

- 容量 $(0.2, 0.3, 0.5)$ の有向3-cycleでは $\mathrm{ANF} = 1.7/6 > 0.2 = \min_s d_x^+(s)$．
- Global mincutには $\kappa_{\mathrm{glob}}(x) \le \min_s d_x^+(s)$ が成り立つ．

**ANFのゲーム解釈**：頂点対は一様分布で固定する．

- 敵が頂点対の分布も自由に選ぶと，平均ではなく global mincut になる．
- ANFでは，各ペアについて最小カットを選び，その値を平均する．

**精度の尺度**：総容量 $1$ に対する上界は $1/n$．この上界だけから，誤差 $\delta = \Theta(1/n)$ の定数比近似は導けない．

# 補足E．カット応答を使った事後の精度確認

**命題E.1（上下界による証明）**．全ての $p \in \Delta_E$ に対して $\mathrm{OBJ}(p) \le \langle g_t, p \rangle$ が成り立つ応答を使うとする．

$$U_T = \max_e \frac{1}{T} \sum_t g_{t,e}, \qquad L_T = \mathrm{OBJ}(\bar{p}_T)$$

と定めると $L_T \le \mathrm{OPT} \le U_T$．従って $0 < \varepsilon < 1$ に対し

$$L_T \ge (1-\varepsilon) U_T \implies \mathrm{OBJ}(\bar{p}_T) \ge (1-\varepsilon)\mathrm{OPT}.$$

**証明**．線形上界を平均して単体上で最大化すると $U_T$ となる．□

この確認には，global mincutのカット，またはANFの全ペア平均を使う． ANFの1ペア抽出の期待値保証とは別の事後確認である．

# 参考文献：MWUとmirror descent


1. A. S. Nemirovski and D. B. Yudin. *Problem Complexity and Method Efficiency in Optimization*. Wiley, 1983. （mirror descentの原型）
2. N. Littlestone and M. K. Warmuth. The Weighted Majority Algorithm. *Information and Computation*, 108(2), 212–261, 1994.
3. Y. Freund and R. E. Schapire. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting. *JCSS*, 55(1), 119–139, 1997.
4. A. Beck and M. Teboulle. Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization. *Operations Research Letters*, 31, 167–175, 2003.
5. S. Arora, E. Hazan, and S. Kale. The Multiplicative Weights Update Method: a Meta-Algorithm and Applications. *Theory of Computing*, 8, 121–164, 2012. （特に指数型更新と二次項評価）

# 参考文献：グラフと一次法


6. M. Fiedler. Algebraic Connectivity of Graphs. *Czechoslovak Mathematical Journal*, 23(2), 298–305, 1973.
7. M. Fiedler. Absolute Algebraic Connectivity of Trees. *Linear and Multilinear Algebra*, 26, 85–106, 1990.
8. D. A. Spielman and S.-H. Teng. Nearly Linear Time Algorithms for Preconditioning and Solving Symmetric, Diagonally Dominant Linear Systems. *SIAM Journal on Matrix Analysis and Applications*, 35(3), 835–885, 2014.
9. 伊藤 勝．凸最適化問題に対する一次法とその理論—加速勾配法とその周辺—．*オペレーションズ・リサーチ*，64(6)，326–334，2019．

# 参考文献：第5章の関連研究


- S. Boyd, P. Diaconis, and L. Xiao. Fastest Mixing Markov Chain on a Graph. *SIAM Review*, 46(4), 667–689, 2004.
- S. Richter and I. Rocha. *Absolute Algebraic Connectivity of Double Brooms and Trees*. *Discrete Applied Mathematics*, 201, 213–221, 2016.
- Y. Wan et al. *On the Structure of Graph Edge Designs that Optimize the Algebraic Connectivity*. *IEEE Conference on Decision and Control*, 805–810, 2008.
- N. M. M. de Abreu. *Old and New Results on Algebraic Connectivity of Graphs*. *Linear Algebra and Its Applications*, 423(1), 53–73, 2007.

# 参考文献：第5章のアルゴリズムと解析


- H. Jiang, Y. T. Lee, Z. Song, and S. C.-W. Wong. An Improved Cutting Plane Method for Convex Optimization, Convex-Concave Games and its Applications. *STOC*, 944–953, 2020.
- S. Shalev-Shwartz. Online Learning and Online Convex Optimization. *Foundations and Trends in Machine Learning*, 4(2), 107–194, 2012.